

UNIVERSIDAD DE ANTIOQUIA

FACULTAD DE INGENIERÍA

DEPARTAMENTO DE ELECTRÓNICA Y TELECOMUNICACIONES

**Trabajo Final: Clasificación Automática de Vocales a
partir de Señales de Voz**

Curso: Tratamiento de Señales I (2026-1)

Integrantes: Oscar David Mercado Gomez
Jose Vicente Zabaleta Montiel

Profesor: Juan Rafael Orozco Arroyave
Daniel Escobar Grisales

Medellín, Antioquia
2026

1. Metodología de Extracción de Características Espectrales

La metodología implementada se basa en la construcción de una representación vectorial de señales de voz utilizando las energías obtenidas a partir de un banco de filtros Mel. El objetivo principal de este procedimiento es transformar cada grabación de audio en un vector de características de dimensión fija que conserve la información espectral más relevante para la identificación de las vocales. Para ello, inicialmente cada señal es cargada y sometida a un proceso de normalización de amplitud, con el propósito de reducir las diferencias debidas a las condiciones de adquisición y garantizar que las características extraídas estén asociadas principalmente a la estructura espectral de la señal y no a variaciones de intensidad. Posteriormente, la señal se divide en ventanas de 50 ms con un solapamiento del 50 %, aplicando una ventana de Hamming a cada segmento para minimizar los efectos de discontinuidad en los extremos de las tramas y obtener estimaciones espectrales más estables.

Una vez segmentada la señal, se calcula la Transformada Rápida de Fourier (FFT) para cada ventana y, a partir de ella, el espectro de potencia. Este espectro describe la distribución de energía de la señal en función de la frecuencia y constituye el punto de partida para la extracción de características. Sin embargo, en lugar de utilizar directamente todas las muestras espectrales, se emplea un banco de filtros Mel para obtener una representación más compacta y adecuada de la información contenida en el espectro. El banco de filtros está formado por 20 filtros triangulares distribuidos sobre la escala Mel. Su construcción se realiza utilizando las transformaciones entre frecuencia lineal y frecuencia Mel implementadas en el proyecto, permitiendo definir bandas de análisis que cubren todo el rango frecuencial considerado. Cada filtro posee una respuesta triangular que pondera las componentes espectrales cercanas a su frecuencia central y atenúa progresivamente las más alejadas. Como resultado, cada filtro acumula la energía presente en una región específica del espectro.

Para cada ventana de análisis, la energía asociada a cada filtro se obtiene mediante la suma ponderada de las componentes del espectro de potencia dentro de su banda de influencia. Este procedimiento genera un conjunto de 20 valores numéricos que representan la distribución de energía de la señal en las distintas bandas Mel. Posteriormente, dichas energías son transformadas a escala logarítmica en decibelios con el objetivo de reducir el rango dinámico de los datos y facilitar la comparación entre muestras. Debido a que una grabación produce múltiples vectores de energía, uno por cada ventana procesada, se calcula el promedio temporal de cada componente a lo largo de toda la señal. De esta manera se obtiene un único vector característico de dimensión 20, donde cada elemento corresponde a la energía promedio de una banda del banco de filtros. Esta representación vectorial resume el comportamiento espectral dominante de la grabación y constituye la característica principal utilizada posteriormente para medir similitud y realizar la clasificación de las vocales.

Nota sobre el uso de herramientas de Inteligencia Artificial: Durante el desarrollo de este proyecto se estima que aproximadamente un 20 % del trabajo fue apoyado mediante herramientas de Inteligencia Artificial. Estas herramientas se utilizaron principalmente para tareas repetitivas de documentación, organización de información y corrección de redacción.